



MEMORIA

Clasificador de canciones: Predicción del género musical

Proyecto de Machine & Deep Learning

By Marta Buesa Suárez de Puga

Febrero 2022



OBJETIVO

Desarrollo de un modelo para la predicción del género musical de las canciones.

Para ello, se parte de una BBDD con 50000 registros de canciones, con 17 features y 1 target que contiene 10 géneros musicales.

Se inicia el trabajo con un Exploratory Data Analysis muy detallado para entender las variables que describen las canciones, para pasar después a la creación de posibles modelos de Machine Learning con Aprendizaje Supervisado, donde se utilizarán 8 algoritmos diferentes.

Asimismo, se utilizará Deep Learning, una red neuronal basada en el algoritmo MultiLabel Perceptron Classifier.

RECURSOS UTILIZADOS

Lenguaje de programación -> Python 3.7.4.

Librerías:

Numpy: especializada en el cálculo numérico y el análisis de datos, especialmente para un gran volumen de datos.

Pandas: especializada en el manejo y análisis de estructuras de datos.

Matplotlib: especializada en la creación de gráficos.

Seaborn: especializada en la creación de gráficos basada en matplotlib pero con una interfaz evolucionada que permite generar fácilmente elegantes gráficos.

Scikit-learn: biblioteca para aprendizaje automático de software libre para el lenguaje de programación Python.

Keras: biblioteca de Redes Neuronales de Código Abierto escrita en Python.

TensorFlow: biblioteca de código abierto para aprendizaje automático a través de un rango de tareas

Jupyter Notebooks con Visual Studio Code.

Csvs: 1 de entrada y 10 de salida obtenidos con modelos

Power Point para explicar el detalle los modelos de Machine & Deep Learning desarrollados

BBDD ORIGEN

<https://www.kaggle.com/vicsuperman/prediction-of-music-genre>

MODELOS DE MACHINE LEARNING DESARROLLADOS

03 Machine & Deep Learning

APRENDIZAJE NO SUPERVISADO

Algoritmos de clasificación

1. Logistic Regresion

Parámetros: `multi_class='multinomial'`

2. Decision Tree -> con Grid Search

Parámetros: `max_depth=10`, `min_samples_leaf=1`

3. SVM - Support Vector Machine

Parámetros: op.1 `C=1` / Op.2 `C=100`

4. Ensemble: Random Forest, Logistic Regression & SVM

Parámetros: `LR(multi_class='multinomial') / RF(n_estimators=100) / SVM(gamma='scale', probability=True)`

5. Random Forest -> con Grid Search

Parámetros: Op.1 `max_depth= 7`, `n_estimators=300`, `max_features= 4` / Op.2 `max_depth= 15`, `n_estimators=35`, `min_samples_leaf=4` / Op.3 `max_depth= 11`, `n_estimators=100`, `min_samples_leaf = 3`

6. Adaptive Boosting

Parámetros: `DecisionTreeClassifier(max_depth=1)`, `n_estimators=200`, `algorithm='SAMME.R'`, `learning_rate=0.5`

7. Gradient Boosting

Parámetros: `learning_rate= 0.3`, `n_estimators= 100`, `max_features= 4`

8. Extreme Gradient Boosting

`n_estimators=100`, `use_label_encoder=False`, `eval_metric = 'logloss'`

ACCURACYS

Algoritmos	ACC Train	ACC Test	Ensembles	ACC Train	ACC Test
1. Logistic Regresion	0.5198	0.5116	5. Random Forest	0.7642	0.5559
2. Decision Tree	0.5855	0.4882	6. Adaptive Boosting	0.5128	0.4962
3. SVM - Support Vector Machine	0.4888	0.4817	7. Gradient Boosting	0.6626	0.5582
4. Ensemble: Random Forest, Logistic Regression & SVM	0.8292	0.5337	8. Extreme Gradient Boosting	0.8155	0.5566

MODELO DE DEEP LEARNING

MultiLayer Perceptron Classifier

Opción 1:

Parámetros: `max_iter=500`

Por defecto pasa la función de activación '`relu`' y optimizador '`adam`' a utilizar para el cálculo del mínimo de la función de coste y

ACC Train	ACC Test
0.6237	0.5758

Opción 2:

Parámetros: `max_iter=500`,
`activation='relu'`, `solver='sgd'`,
`hidden_layer_sizes = (150, 100)`

Distinto optimizador 'descenso de gradiente estocástico', e incluyo 2 capas de 150 y 100 neuronas

ACC Train	ACC Test
0.6445	0.5741

Opción 3:

Parámetros: `max_iter=500`,
`activation='tanh'`, `solver='sgd'`,
`hidden_layer_sizes = (150, 100)`

Cambio función de activación a la tangente hiperbólica, con el descenso de gradiente estocástico y de nuevo 2 capas de neuronas

ACC Train	ACC Test
0.6239	0.5811

PRESENTACIÓN

<https://speakerdeck.com/tukibuesa/martabuesa-proyecto-ml-pptcompleta>

CONCLUSIONES

Para mejorar los resultados en la predicción del género musical, las posibles soluciones pasarían por:

- 1. CONSEGUIR MAS DATOS** en este caso particular ya contaba con 50000 registros para el estudio.
- 2. CONSEGUIR MÁS FEATURES**, variables descriptivas que puedan predecir mejor los distintos géneros musicales.
- 3.** Si no se pudiera obtener más información, **REDEFINIR LOS GÉNEROS MUSICALES A PREDECIR**, posiblemente reagrupando aquellos que tienen unas características similares, para permitir a los modelos una predicción más certera.

AGRADECIMIENTOS

Especialmente agradecida a mi escuela The Bridge Digital Talent Accelerator por darme la oportunidad de desarrollarme en Data Science, y en concreto a mis profesores Alberto Romero, Julia Martínez y Rafael Manzano, por su dedicación, entusiasmo e interés por transmitirnos todo su conocimiento, así como apoyo para desarrollar todo mi potencial.